

基于特征选择与贝叶斯优化的智能制造效率预测研究

强基班

摘要

智能制造环境下设备效率状态的精准预测对生产优化具有重要意义。本研究针对工业物联网传感器数据与 6G 网络性能指标的高维特性，提出一种融合多指标的特征选择与贝叶斯优化的预测框架。首先通过随机森林、互信息、相关系数和偏相关系数四种评估筛选出关键特征；随后构建贝叶斯优化的 XGBoost 和全连接网络模型；创新性地引入多项式特征扩展增强非线性表征能力。实验结果表明，仅使用 2 个关键特征 (Error_Rate% 和 Production_Speed) 即可达到和全特征一致的预测准确率，同时计算效率大幅提升。特征扩展后模型准确率进一步提升至 99.83%，SHAP 可解释性分析揭示了特征间的非线性交互效应。该方法在保证预测精度的同时显著降低了计算复杂度，为智能制造系统的实时决策提供了有效支持。

1 研究背景

工业 4.0 时代背景下，智能制造系统通过工业物联网传感器实时采集设备运行状态数据，结合 6G 网络切片技术实现高效数据传输，为生产过程优化提供了数据基础。效率状态 (Efficiency_Status) 作为综合评价设备运行效能的关键指标，对其进行精准预测能够有效指导预测性维护、资源调度优化等决策，对提升制造系统的整体效能具有重要意义。

当前智能制造效率预测面临三大挑战：首先，多源异构传感器数据（温度、振动、功耗等）与网络性能指标（延迟、丢包率等）构成的高维特征空间存在显著冗余，直接使用全特征建模会导致计算复杂度高且易产生过拟合；其次，传统超参数优化方法（如网格搜索）在复杂模型上计算效率低下，难以满足实时性要求；最后，工业场景对模型决策可解释性的需求日益增强，需要清晰理解特征对预测结果的影响机制。

前人研究在智能制造效率预测领域取得了一定进展：Zhang 等人（2023）提出基于随机森林与互信息融合的特征选择框架 (RF-MI)，有效降低高维传感器数据冗余性，特征维度缩减 40% 同时保持 98% 预测准确率；Chen 等人（2024）利用贝叶斯优化替代网格搜索优化 LSTM 超参数，训练时间缩短 60% 且均方误差降低 22%；Wang 等人（2022）引入 SHAP 方法增强模型可解释性，可视化特征贡献度以定位关键因素；Li 等人（2023）设计融合工业物联网与 6G 网络切片的集成框架，生产调度延迟降低 35%。然而，这些研究存在以下不足：特征选择未考虑网络性能指标与传感器数据的动态耦合关系，依赖单一评估准则导致泛化能力受限；超参数优化未解决与网络结构设计的协同问题，且缺乏在资源受限边缘设备上的实时性验证；可解释性技术计算复杂度高，难以满足毫秒级实时决策需求，且未与特征选择机制联动优化；集成框架缺乏对特征选择与模型可解释性的系统性支持，导致优化决策透明度不足和适应性弱。

针对上述问题，本研究提出创新解决方案：1) 设计多准则特征选择机制，综合随机森林、互信息和相关系数评估特征重要性；2) 采用贝叶斯优化实现高效的超参数搜索与网络结构优化；3) 结合特征工程与模型可解释性技术，构建透明可靠的预测框架。通过在真实智能制造数据集上的系统验证，为智能制造系统的智能化升级提供了技术支撑。

2 算法设计

2.1 随机森林算法

随机森林 (Random Forest) 是一种集成学习方法，通过构建多棵决策树并综合其预测结果来提高模型的泛化能力。其核心思想在于通过特征和样本的双重随机性降低模型方差，提升预测稳定性。给定训练数据集 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ ，其中 $\mathbf{x}_i \in \mathbb{R}^M$ 为特征向量， $y_i \in \mathcal{Y}$ 为标签，随机森林的构建过程可形式化描述如下：

1. **自助采样 (Bootstrap)**: 对于每棵决策树 t ，从原始数据集中进行有放回抽样得到训练子集 $\mathcal{D}_t$ ，样本规模通常保持为 N 。未被采中的样本构成袋外数据 (Out-Of-Bag, OOB)，用于模型验证。
2. **特征随机选择**: 在决策树的每个节点分裂时，从全部 M 个特征中随机选择 m 个特征作为候选 (通常 $m = \sqrt{M}$)，从中选择最优分裂点。
3. **决策树构建**: 基于基尼系数或信息增益构建决策树，递归地进行节点分裂直至满足终止条件 (节点纯度达到阈值或达到最大深度)。基尼系数定义为：

$$\text{Gini}(p) = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2 \quad (1)$$

其中 K 为类别数， p_k 为节点中第 k 类样本的比例。分裂时选择使子节点加权基尼不纯度最小的特征和阈值：

$$\Delta \text{Gini} = \text{Gini}(p) - \frac{N_{\text{left}}}{N} \text{Gini}(p_{\text{left}}) - \frac{N_{\text{right}}}{N} \text{Gini}(p_{\text{right}}) \quad (2)$$

4. **特征重要性计算**: 通过计算特征在所有树中的分裂效果评估特征重要性：

$$\text{Importance}_j = \frac{1}{T} \sum_{t=1}^T \sum_{\text{node} \in S_j} \frac{N_{\text{node}}}{N} \Delta I(\text{node}) \quad (3)$$

其中 S_j 表示所有以特征 j 分裂的节点， $\Delta I(\text{node})$ 为该节点分裂前后的不纯度减少量。

Algorithm 1 随机森林训练

输入: 训练数据 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, 树数量 T , 特征采样比例 m

输出: 随机森林模型 $\mathcal{F} = \{f_t\}_{t=1}^T$

- 1: $\mathcal{F} \leftarrow \emptyset$ 初始化空模型集合
 - 2: **for** $t \leftarrow 1$ **to** T **do**
 - 3: $\mathcal{D}_t \leftarrow \text{BootstrapSample}(\mathcal{D})$ 有放回采样训练子集
 - 4: $f_t \leftarrow \text{BuildDecisionTree}(\mathcal{D}_t, m)$ 构建决策树
 - 5: $\mathcal{F} \leftarrow \mathcal{F} \cup \{f_t\}$ 添加至模型集合
 - 6: **end for** **return** $\mathcal{F}$
-

2.2 贝叶斯优化

贝叶斯优化 (Bayesian Optimization, BO) 作为全局优化算法，通过概率代理模型实现高效的超参数搜索。给定超参数空间 $\mathcal{X} \subseteq \mathbb{R}^d$ 和目标函数 $f: \mathcal{X} \rightarrow \mathbb{R}$ (如模型验证集准确率)，BO 的核心思想是通过构建目标函数的概率模型，智能选择评估点以快速逼近全局最优解。

高斯过程先验: 假设目标函数服从高斯过程：

$$f(\mathbf{x}) \sim \mathcal{GP}(\mu(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \quad (4)$$

其中 $\mu(\cdot)$ 为均值函数（通常设为常数）， $k(\cdot, \cdot)$ 为协方差函数（核函数）。常用的径向基函数（RBF）核定义为：

$$k(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{1}{2}\|\mathbf{x}_i - \mathbf{x}_j\|^2/\ell^2\right) \quad (5)$$

其中 ℓ 为长度尺度参数。

给定观测数据集 $\mathcal{D}_{1:n} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，其中 $y_i = f(\mathbf{x}_i) + \epsilon_i$ ， $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ 为观测噪声，函数值的联合分布为：

$$\mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma^2 \mathbf{I}) \quad (6)$$

其中 $\mathbf{K} \in \mathbb{R}^{n \times n}$ 为核矩阵，元素 $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ 。

后验分布：对于新点 $\mathbf{x}_{n+1}$ ，函数值的后验分布为：

$$p(f_{n+1}|\mathcal{D}_{1:n}, \mathbf{x}_{n+1}) \sim \mathcal{N}(\mu_n(\mathbf{x}_{n+1}), \sigma_n^2(\mathbf{x}_{n+1})) \quad (7)$$

后验均值和方差分别为：

$$\mu_n(\mathbf{x}) = \mathbf{k}^T (\mathbf{K} + \sigma^2 \mathbf{I})^{-1} \mathbf{y} \quad (8)$$

$$\sigma_n^2(\mathbf{x}) = k(\mathbf{x}, \mathbf{x}) - \mathbf{k}^T (\mathbf{K} + \sigma^2 \mathbf{I})^{-1} \mathbf{k} \quad (9)$$

其中 $\mathbf{k} = [k(\mathbf{x}, \mathbf{x}_1), \dots, k(\mathbf{x}, \mathbf{x}_n)]^T$ 。

采集函数：通过采集函数 $\alpha(\mathbf{x})$ 选择下一个评估点，常用的期望改进（EI）函数定义为：

$$\alpha_{\text{EI}}(\mathbf{x}) = \mathbb{E}[\max(f(\mathbf{x}) - f^+, 0)] \quad (10)$$

其中 $f^+ = \max_{i=1, \dots, n} f(\mathbf{x}_i)$ 为当前最优观测值。其闭式解为：

$$\alpha_{\text{EI}}(\mathbf{x}) = (\mu(\mathbf{x}) - f^+ - \xi)\Phi(Z) + \sigma(\mathbf{x})\phi(Z) \quad (11)$$

其中 $Z = \frac{\mu(\mathbf{x}) - f^+ - \xi}{\sigma(\mathbf{x})}$ ， Φ 和 ϕ 分别为标准正态分布的累积分布函数和概率密度函数， ξ 为探索系数。

Algorithm 2 贝叶斯优化

输入：目标函数 f ，搜索空间 $\mathcal{X}$ ，迭代次数 T

输出：最优解 $\mathbf{x}^*$

1: 初始化观测点集 $\mathcal{D} \leftarrow \{(\mathbf{x}_i, f(\mathbf{x}_i))\}_{i=1}^{n_{\text{init}}}$

2: **for** $t \leftarrow 1$ to T **do**

3: 基于 $\mathcal{D}$ 拟合高斯过程 $\mathcal{GP}$

4: $\mathbf{x}_t \leftarrow \arg \max_{\mathbf{x} \in \mathcal{X}} \alpha_{\text{EI}}(\mathbf{x})$

最大化采集函数

5: $y_t \leftarrow f(\mathbf{x}_t)$

评估目标函数

6: $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\mathbf{x}_t, y_t)\}$

7: **end for**

8: $\mathbf{x}^* \leftarrow \arg \max_{(\mathbf{x}, y) \in \mathcal{D}} y$ **return** $\mathbf{x}^*$

2.3 XGBoost 算法

XGBoost (eXtreme Gradient Boosting) 是一种高效的梯度提升决策树 (GBDT) 实现，通过二阶泰勒展开和正则化项优化目标函数。给定数据集 $\mathcal{D}$ ，集成模型由 K 棵回归树组成：

$$\hat{y}_i = \sum_{k=1}^K f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F} \quad (12)$$

其中 $\mathcal{F}$ 为回归树空间，每棵树 f_k 将样本映射到叶子节点得分。

目标函数： XGBoost 的目标函数包含损失函数和正则化项：

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (13)$$

其中 $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2$ ， T 为叶子节点数， $\mathbf{w}$ 为叶子得分向量。

泰勒展开： 在第 t 次迭代时，通过二阶泰勒展开近似目标函数：

$$\begin{aligned} \mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t) \\ + \text{常数项} \end{aligned} \quad (14)$$

其中 $g_i = \partial_{\hat{y}} l(y_i, \hat{y})$, $h_i = \partial_{\hat{y}}^2 l(y_i, \hat{y})$ 。

节点分裂： 定义叶子节点 j 的样本集合 $I_j = \{i | q(\mathbf{x}_i) = j\}$ ，目标函数可改写为：

$$\mathcal{L}^{(t)} = \sum_{j=1}^T \left[\left(\sum_{i \in I_j} g_i \right) w_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) w_j^2 \right] + \gamma T \quad (15)$$

最优叶子权重为：

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (16)$$

最优目标函数值为：

$$\mathcal{L}^{(t)} = - \frac{1}{2} \sum_{j=1}^T \frac{(\sum_{i \in I_j} g_i)^2}{\sum_{i \in I_j} h_i + \lambda} + \gamma T \quad (17)$$

分裂时选择使增益最大的特征和阈值：

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma \quad (18)$$

其中 $G_L = \sum_{i \in I_L} g_i$, $H_L = \sum_{i \in I_L} h_i$ 等。

Algorithm 3 XGBoost 训练

输入： 训练数据 $\mathcal{D}$ ，树数量 K ，学习率 η

输出： 集成模型 $\mathcal{M} = \{f_k\}_{k=1}^K$

- 1: 初始化模型 $\hat{y}_i^{(0)} = 0$
 - 2: **for** $k \leftarrow 1$ to K **do**
 - 3: 计算梯度 g_i 和海森矩阵 h_i
 - 4: 构建决策树 f_k 以最小化目标函数
 - 5: 更新模型: $\hat{y}_i^{(k)} = \hat{y}_i^{(k-1)} + \eta f_k(\mathbf{x}_i)$
 - 6: **end for** return $\mathcal{M}$
-

2.4 全连接神经网络

全连接神经网络 (Fully Connected Neural Network) 是一种基础的前馈神经网络结构，通过多层非线性变换学习复杂映射关系。给定 L 层网络，第 l 层的计算可表示为：

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = g^{(l)}(\mathbf{z}^{(l)}) \quad (19)$$

其中 $\mathbf{a}^{(0)} = \mathbf{x}$ 为输入, $\mathbf{a}^{(L)} = \hat{\mathbf{y}}$ 为输出, $g^{(l)}$ 为激活函数。

反向传播: 通过链式法则计算梯度, 定义第 l 层误差:

$$\delta^{(l)} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{(l)}} \quad (20)$$

输出层误差:

$$\delta^{(L)} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{(L)}} \odot g'^{(L)}(\mathbf{z}^{(L)}) \quad (21)$$

隐层误差:

$$\delta^{(l)} = (\mathbf{W}^{(l+1)T} \delta^{(l+1)}) \odot g'^{(l)}(\mathbf{z}^{(l)}) \quad (22)$$

参数梯度:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} \mathbf{a}^{(l-1)T} \quad (23)$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{(l)}} = \delta^{(l)} \quad (24)$$

特征扩展: 为增强非线性表征能力, 可对输入特征进行多项式变换:

$$\phi(\mathbf{x}) = [x_1, x_1^2, \dots, x_1^d, \exp(|x_1|), \exp(x_1^2), \dots]^T \quad (25)$$

其中 d 为多项式阶数。扩展后的特征向量作为网络输入。

正则化: 通过 L2 正则化和 Dropout 防止过拟合:

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \frac{\lambda}{2} \sum_{l=1}^L \|\mathbf{W}^{(l)}\|_F^2 \quad (26)$$

Dropout 在训练时以概率 p 随机将神经元输出置零, 测试时缩放权重。

Algorithm 4 全连接神经网络训练

输入: 训练数据 $\mathcal{D}$, 网络结构 $\{n_l\}_{l=0}^L$, 学习率 η

输出: 网络参数 $\theta = \{\mathbf{W}^{(l)}, \mathbf{b}^{(l)}\}_{l=1}^L$

- 1: 初始化参数 θ
 - 2: **for** epoch = 1 to E **do**
 - 3: **for** 每个小批量 $\mathcal{B} \subset \mathcal{D}$ **do**
 - 4: 前向传播计算输出 $\hat{\mathbf{y}}$
 - 5: 计算损失 $\mathcal{L}$
 - 6: 反向传播计算梯度 $\nabla_{\theta} \mathcal{L}$
 - 7: 更新参数: $\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$
 - 8: **end for**
 - 9: **end for** **return** θ
-

2.5 SHAP 可解释性分析

SHAP (SHapley Additive exPlanations) 是一种基于博弈论的解释框架, 为机器学习模型预测提供统一的可解释性度量。其核心思想源自合作博弈论的 Shapley 值理论, 通过计算每个特征对预测结果的边际贡献分配特征重要性。给定预测模型 f 和输入样本 $\mathbf{x}$, SHAP 值计算可形式化描述如下:

1. **特征贡献分配**: 将模型预测值 $f(\mathbf{x})$ 分解为各特征贡献之和:

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^M \phi_j(f, \mathbf{x}) \quad (27)$$

其中 ϕ_0 为基线期望值, ϕ_j 为特征 j 的 SHAP 值。

2. **Shapley 值计算**: 对每个特征 j , 计算其在所有特征子集中出现的边际贡献:

$$\phi_j(f, \mathbf{x}) = \sum_{S \subseteq M \setminus \{j\}} \frac{|S|!(|M| - |S| - 1)!}{|M|!} [f(S \cup \{j\}) - f(S)] \quad (28)$$

其中 M 为特征全集 ($|M| = m$), S 为不含 j 的特征子集, $f(S)$ 表示仅使用 S 中特征进行预测。

3. **条件期望近似**: 实际计算中, $f(S)$ 通过条件期望近似:

$$f(S) = \mathbb{E}[f(\mathbf{x}) | \mathbf{x}_S] = \int f(\mathbf{x}_S, \mathbf{x}_{\setminus S}) p(\mathbf{x}_{\setminus S} | \mathbf{x}_S) d\mathbf{x}_{\setminus S} \quad (29)$$

其中 $p(\mathbf{x}_{\setminus S} | \mathbf{x}_S)$ 为特征条件分布。

4. **模型无关实现**: 通过核函数加权局部回归求解 SHAP 值:

$$\min_{\phi_0, \phi_1, \dots, \phi_m} \sum_{\mathbf{z}' \in Z} \left[f(h_{\mathbf{x}}(\mathbf{z}')) - \sum_{j=0}^m \phi_j \mathbf{z}'_j \right]^2 \pi(\mathbf{z}') \quad (30)$$

$$\text{s.t. } \phi_j(f, \mathbf{x}) = \phi_j \quad \forall j \quad (31)$$

其中 $h_{\mathbf{x}}$ 为映射函数, $\pi(\mathbf{z}')$ 为 Shapley 核权重:

$$\pi(\mathbf{z}') = \frac{m-1}{\binom{m}{|z'|} |z'| (m - |z'|)} \quad (32)$$

Algorithm 5 SHAP 值计算 (KernelSHAP)

输入: 预测模型 f , 解释样本 $\mathbf{x}$, 背景数据集 Z , 采样次数 K

输出: SHAP 值向量 $\phi \in \mathbb{R}^m$

- 1: $\phi \leftarrow \mathbf{0} \in \mathbb{R}^m$ 初始化贡献向量
 - 2: **for** $k \leftarrow 1$ **to** K **do**
 - 3: 随机生成特征子集 $S \subseteq M$ Bernoulli 抽样
 - 4: 构建映射样本: $\mathbf{z}' \leftarrow [1, \mathbf{1}_{\{j \in S\}}] \quad \forall j = 1, \dots, m$
 - 5: 计算特征映射: $\mathbf{z} \leftarrow \mathbf{x}_S \cup \mathbf{z}_{\setminus S}^{(k)}$ 从 Z 抽样填充
 - 6: 预测值: $y_k \leftarrow f(\mathbf{z})$
 - 7: 核权重: $w_k \leftarrow \pi(\mathbf{z}')$ 由式 (32)
 - 8: 数据矩阵填充: $A[k, :] \leftarrow \mathbf{z}', b[k] \leftarrow y_k$
 - 9: **end for**
 - 10: 解加权最小二乘: $\phi \leftarrow \arg \min_{\phi} \|\text{diag}(\mathbf{w})(A\phi - \mathbf{b})\|^2$ **return** ϕ
-

SHAP 值满足以下重要数学性质:

- **可加性**: $\sum \phi_j = f(\mathbf{x}) - \mathbb{E}[f(\mathbf{x})]$
- **一致性**: 若特征 j 对模型输出的贡献增加, 则 ϕ_j 不减少
- **缺失特征**: $\phi_j = 0$ 当特征 j 不影响预测 ($f(S \cup \{j\}) = f(S)$)

通过可视化分析 (特征重要性图、决策图、热力图等), SHAP 为工业用户提供直观模型决策解释, 支持智能制造中的关键决策制定。

3 仿真设计与算法测试

3.1 数据集与实验环境

本研究所使用的智能制造数据集来源于工业物联网传感器与 6G 网络性能指标的实时采集，数据获取地址为：<https://www.kaggle.com/datasets/ziya07/intelligent-manufacturing-dataset/data>。数据集覆盖 2024 年 1 月 1 日至 3 月 10 日期间的生产数据，共计 100,000 条样本，包含 13 个特征维度。特征统计信息如表1所示。

表 1: 智能制造数据集特征统计

特征名称	类型	范围	单位
时间戳	时间序列	2024-01-01 至 2024-03-10	-
Machine_ID	分类	1-50	0 -
Operation_Mode	分类	{Active, Idle, Maintenance }	-
Temperature_C	连续	[1.00, 50.00]	°C
Vibration_Hz	连续	[30.00, 90.00]	Hz
Power_Consumption_kW	连续	[0.10, 5.00]	kW
Network_Latency_ms	连续	[1.50, 10.00]	ms
Packet_Loss_%	连续	[1.00, 50.00]	0 %
Error_Rate_%	连续	[0.00, 5.00]	%
Production_Speed	连续	[50.00, 500.00]	单位/小时
Efficiency_Status	分类	{High, Medium, Low}	-

3.2 数据预处理流程

3.2.1 特征编码

对分类特征进行独热编码：

$$\text{Operation_Mode} \rightarrow \begin{cases} \text{Active} & [1, 0, 0] \\ \text{Idle} & [0, 1, 0] \\ \text{Maintenance} & [0, 0, 1] \end{cases} \quad (33)$$

$$\text{Machine_ID} \rightarrow \text{OneHotEncode}(1 \text{ to } 50) \quad (34)$$

3.2.2 数据标准化

对连续特征进行 Z-score 标准化：

$$z = \frac{x - \mu}{\sigma} \quad (35)$$

其中 μ 为特征均值， σ 为标准差。标准化后各特征均值为 0，标准差为 1。

3.2.3 数据集划分

采用分层抽样保证各类别比例一致：

$$\mathcal{D}_{\text{train}} : \mathcal{D}_{\text{val}} : \mathcal{D}_{\text{test}} = 70\% : 15\% : 15\% \quad (36)$$

训练集用于模型训练，验证集用于超参数优化，测试集用于最终评估。

3.3 实验设计

3.3.1 特征选择实验

1. **随机森林特征重要性**: 构建 100 棵决策树，最大深度 8，节点分裂所需的最小样本数 10，每次分裂时考虑的特征数为 $\log_2(n_features)$ ，每棵树只使用 70% 的样本进行训练，增加多样性，固定随机种子为 42，确保结果可复现，计算特征重要性。

2. **互信息分析**: 基于离散化特征计算:

$$I(X;Y) = \sum_{y \in Y} \sum_{x \in X} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \quad (37)$$

3. **皮尔逊相关系数**:

$$\rho_{X,Y} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y} \quad (38)$$

4. **偏相关系数**:

$$\rho_{XY \cdot Z} = \frac{\rho_{XY} - \rho_{XZ}\rho_{YZ}}{\sqrt{(1 - \rho_{XZ}^2)(1 - \rho_{YZ}^2)}} \quad (39)$$

综合上述方法列出前 15 重要特征，然后进行特征的筛选。

3.3.2 贝叶斯优化 XGBoost 实验

我们采用贝叶斯优化方法对 XGBoost 模型进行超参数调优，具体流程如下:

给定训练集 D_{train} 、验证集 D_{val} 和超参数空间 Θ ，寻找最优模型 f^* 及其对应的超参数 θ^* 。定义目标函数为:

$$f(\theta) = 1 - \text{Accuracy}(f_\theta(D_{val})) \quad (40)$$

贝叶斯优化过程如下:

1. 初始化高斯过程 $GP(\mu, k)$

2. 对于 $t \leftarrow 1$ 到 50:

- 通过最大化采集函数 $\alpha_{EI}(\theta)$ 选择下一组超参数:

$$\theta_t \leftarrow \arg \max_{\theta \in \Theta} \alpha_{EI}(\theta) \quad (41)$$

- 使用 θ_t 训练 XGBoost 模型 f_{θ_t} 于 D_{train}
- 在 D_{val} 上评估模型性能: $y_t = f(\theta_t)$
- 更新观测数据集: $D_{BO} \leftarrow D_{BO} \cup \{(\theta_t, y_t)\}$
- 更新高斯过程 GP

3. 确定最优超参数:

$$\theta^* \leftarrow \arg \min_{\theta} D_{BO \cdot y} \quad (42)$$

4. 使用 θ^* 在 $D_{train} \cup D_{val}$ 上训练最终模型 f^* 。

超参数空间 Θ 定义如下: 学习率: $\eta \in [0.01, 0.3]$ 、最大深度: $d \in \{3, 4, \dots, 15\}$ 、子采样率: $r \in [0.6, 1.0]$ 、最小子样本权重: $w \in [1, 10]$ 、正则化参数: $\alpha, \lambda \in [0, 5]$ 。

实验分为两个任务分别执行: 全特征输入 (13 维特征) 和双特征输入 (特征 A+B)。

3.3.3 贝叶斯优化多层全连接网络实验

网络结构超参数空间：隐藏层数： $L \in \{1, 2, 3\}$ 、每层神经元数： $n_l \in [50, 200]$ 、激活函数：*textSigmoid*、学习率： $\eta \in [10^{-5}, 5 * 10^{-2}]$ 、Dropout 率： $p \in [10^{-8}, 10^{-2}]$ 。

目标函数：

$$f(\theta) = 1 - \frac{1}{3}(\text{Acc}_H + \text{Acc}_M + \text{Acc}_L) \quad (43)$$

其中 Acc_H 、 Acc_M 、 Acc_L 分别为高、中、低效率状态的召回率。

同样执行两个任务：全特征输入（13 维）和双特征输入（特征 A+B）。

3.3.4 多项式特征扩展实验

对筛选出的关键特征进行多项式扩展：

$$\phi(\mathbf{x}) = \left[A, A^2, A^3, A^4, A^5, \exp(|A|), \exp(A^2), B, B^2, B^3, B^4, B^5, \exp(|B|), \exp(B^2) \right]^T \quad (44)$$

得到 14 维特征向量。使用单隐藏层全连接网络，采用贝叶斯优化搜索最优超参数。

3.3.5 SHAP 可解释性分析

对每个训练完成的模型进行 SHAP 值计算：

$$\phi_i(f, \mathbf{x}) = \sum_{S \subseteq M \setminus \{i\}} \frac{|S|!(|M| - |S| - 1)!}{|M|!} [f(S \cup \{i\}) - f(S)] \quad (45)$$

其中 M 为特征集合， S 为特征子集。生成这些可视化：特征重要性图： $\|\phi_i\|$ 排序、特征交互热力图： $\mathbb{E}[\phi_{ij}]$ 、决策边界图（二维特征模型）、单样本预测分解图。

3.4 评估指标

采用多类别分类评估指标：

1. 准确率：

$$\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i) \quad (46)$$

2. 混淆矩阵：计算每个类别的 TP、FP、FN、TN

3. 宏平均 F1：

$$\text{F1}_{\text{macro}} = \frac{1}{C} \sum_{c=1}^C \frac{2 \cdot \text{Prec}_c \cdot \text{Rec}_c}{\text{Prec}_c + \text{Rec}_c} \quad (47)$$

4. 计算效率：训练时间。

3.5 总结

本节建立了完整的实验验证体系，从数据预处理、特征选择到模型优化形成系统化研究方案。通过设计多阶段特征选择实验，将综合评估随机森林、互信息和相关系数等方法的特征筛选效果；贝叶斯优化实验针对 XGBoost 和全连接网络分别构建超参数搜索空间，重点验证其在高低维特征空间的适应性；多项式特征扩展实验将检验非线性变换对模型性能的影响。所有实验均采用分层抽样保证数据代表性，并设置多维度评估指标。

4 结果分析与讨论

4.1 特征选择结果

如图1所示，通过随机森林 (RF)、互信息 (MI)、相关系数 (Corr) 和偏相关系数 (Pr) 四种方法评估的特征重要性呈现高度一致性。生产错误率 (Error_Rate%) 与生产速度 (Production_Speed) 在所有评估方法中均位列前二，表明其在制造效率预测中的核心地位。这一现象可形式化为以下互信息计算：

$$I(X;Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \quad (48)$$

其中 $I(X;Y)$ 量化了特征 X 与目标变量 Y 的统计相关性。值得注意的是，当仅采用双特征组合时，模型预测性能损失很小，充分验证了特征选择策略对高维工业数据集的有效压缩能力。




图 1: 四种方法特征重要性对比 (RF/MI/Corr/Pr 前 15 特征)

4.2 模型性能对比

为全面评估模型效能，图2展示了 XGBoost 与多层全连接网络 (M-FCN) 在特征维度变化下的性能表现对比。根据实验数据有以下发现：

首先，全特征模型中多层神经网络 (M-FCN) 达到 99.43% 的最高准确率，略微弱于 XGBoost 的 99.80%，体现出本预测任务的准确率对于模型的选择并不敏感。其次，特征提取使 XGBoost 训练时间从 66.76 秒降至 37.65 秒，计算效率提升 43.64%，更加满足工业实时预测需求。尤其值得注意的是，双特征场景下 M-FCN 模型预测准确率上升至 99.64%，证实在关键特征识别准确的前提下，特征降维可极大优化运算效率甚至于提升预测精度。

表2量化展示了不同于特征和模型选择带来的准确率和总运行时间的对比。可以看出，本任务对模型选择并不敏感；XGBoost 模型进行特征选择后，时间上有大幅提升；多层 FCN 模型进行特征选择后，时间上只是略有提升；XGBoost 相对于多层 FCN 模型有全面的优势，尤其是在速度上。




图 2: 模型准确率与训练时间综合对比

表 2: 模型性能量化对比

模型	准确率 (%)	训练时间 (s)
XGBoost(全特征)	99.80	66.76
XGBoost(双特征)	99.80	37.65
FCN(全特征)	99.43	397.57
FCN(双特征)	99.64	381.51

4.3 特征扩展效果

通过贝叶斯优化调参后的模型对比显示 (表3), 多项式特征扩展显著提升了模型性能。未扩展特征的基础模型准确率为 99.60%, 而经过非线性多项式扩展后, 模型达到了所有模型里最高的 99.83% 测试准确率, 提升幅度达 0.23%。

这种性能提升源于多项式扩展对模型表达能力的增强:

$$\mathcal{H} = \{h \in \mathcal{H}_d | h(\mathbf{x}) = \prod_{j=1}^d x_j^{k_j}, \sum k_j \leq 2\} \quad (49)$$

其中 $\mathcal{H}_d$ 为 d 维多项式假设空间, 阶数约束 k 控制模型复杂度。扩展后的特征空间能更精细地描述高维结构, 有效解决临界点样本的错分类的问题。

4.4 可解释性分析

全局特征重要性图 (图3a) 揭示了不同特征对目标特征不同类别的贡献。图3b的热力分析进一步显示关键特征的对结果的重要影响。


决策边界可视化 (图4) 直观展示了模型对特征空间的划分逻辑。单层全连接模型的边界有更多凹凸 (图4a), 而双特征模型形成更加光滑的边界 (图4b), 边界形态差异解释了特征工程对模型性能的提升作用。

表 3: 多项式特征扩展效果对比 (贝叶斯超参数寻优后)


未扩展特征 (准确率: 0.9960)				
类别	精确率	召回率	F1 分数	支持数
Low (低效)	0.9427	0.9933	0.9673	298
Medium (中效)	1.0000	0.9974	0.9987	7745
High (高效)	0.9888	0.9908	0.9898	1957

* 全文最高测试准确率

多项式扩展后 (准确率: 0.9983*)				
类别	精确率	召回率	F1 分数	支持数
Low (低效)	1.0000	0.9800	0.9900	299
Medium (中效)	1.0000	1.0000	1.0000	7782
High (高效)	1.0000	0.9900	0.9950	1919




(a) SHAP 特征重要性分析



(b) 特征交互热力图

图 3: 可解释性分析结果



(a) 单层 FCN 决策边界

(b) 双特征模型决策边界

图 4: 关键特征决策边界对比

5 结论

本研究针对智能制造效率预测问题，提出融合贝叶斯优化与特征工程的混合框架，主要贡献如下：

- **特征精简**：双特征组合无损准确率前提下，采用 XGBoost 模型训练速度提升 43.64%；
- **算法优化**：多项式扩展使提高了单层全连接神经网络的测试准确率，达到 99.83%；

通过决策边界可视化与 SHAP 分析的协同验证，建立了”特征选择-模型优化-解释验证”的闭环工作框架，为智能制造系统提供了可靠的可解释性预测方案。

参考文献

- [1] Breiman, L. (2001). Random forests. *Machine learning*, 45(1), 5-32. DOI: 10.1023/A:1010933404324
- [2] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 785-794). DOI: 10.1145/2939672.2939785
- [3] Snoek, J., Larochelle, H., & Adams, R. P. (2012). Practical Bayesian optimization of machine learning algorithms. *Advances in neural information processing systems*, 25, 2951-2959. PDF
- [4] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536. DOI: 10.1038/323533a0
- [5] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Proceedings of the 31st international conference on neural information processing systems* (pp. 4768-4777). PDF
- [6] Miadul, M. (2025). *Operational efficiency & fault prediction in manufacturing*. Kaggle. <https://www.kaggle.com/code/miadul/operational-efficiency-fault-prediction-in-machi>
- [7] Devraai, A. (2025). *Intelligent manufacturing predictor*. Kaggle. <https://www.kaggle.com/code/devraai/intelligent-manufacturing-predictor>
- [8] Khandekar, K. (2025). *Prediction via classifier chain (sklearn)*. Kaggle. <https://www.kaggle.com/code/kkhandekar/prediction-via-classifier-chain-sklearn>
- [9] Xu, Y., Li, X., Chen, S., & Liu, D. (2021). Industrial IoT enabled supply-side energy modelling for smart energy management. *Applied Energy*, 304, 117680. DOI: 10.1016/j.apenergy.2021.117680

附录 A

在本文研究过程中，特征选择环节主要参考了代码库中的以下方法：

- **预测特征选择**：基于领域知识与数据探索性分析，从原始特征集中筛选出最具预测力的特征子集，确保模型输入的相关性与简洁性。
- **随机森林特征排序**：采用随机森林算法的内置特征重要性评估功能，通过计算基尼不纯度下降或排列重要性得分，对特征进行优先级排序，实现数据驱动的特征筛选。